

Matriz de decisión de costos y modelos

Para este ecosistema se compararon distintos modelos según costo, velocidad, complejidad de la tarea y conveniencia operativa. La automatización trabaja con leads comerciales, por lo tanto la tarea principal no requiere razonamiento complejo: necesita interpretar intención, clasificar prioridad y generar una respuesta breve para revisión humana.

Modelo: GPT-4.1

Costo aprox.: Input USD 2.00 / Output USD 8.00 por 1M tokens.

Uso recomendado: pruebas iniciales, validación de calidad y casos comerciales más complejos.

Decisión: se utilizó en el prototipo porque permite validar la arquitectura completa con buena calidad de respuesta.

Modelo: GPT-4.1 mini

Costo aprox.: Input USD 0.40 / Output USD 1.60 por 1M tokens.

Uso recomendado: operación diaria de clasificación de leads y generación de respuestas breves.

Decisión: es el modelo recomendado para producción por su mejor relación entre costo y capacidad.

Modelo: GPT-4o mini

Costo aprox.: Input USD 0.15 / Output USD 0.60 por 1M tokens.

Uso recomendado: tareas simples, repetitivas y de bajo costo, como clasificación masiva o respuestas comerciales simples.

Decisión: es la alternativa más económica para escalar el sistema si se prioriza reducción de costos.

Modelo: Claude Haiku 4.5

Costo aprox.: Input USD 1.00 / Output USD 5.00 por 1M tokens.

Uso recomendado: alternativa liviana si la arquitectura se migrara a Anthropic.

Decisión: no se eligió para este prototipo porque la integración práctica fue armada con OpenAI.

Opción: Batch API

Costo aprox.: descuento del 50% para procesamiento por lotes.

Uso recomendado: procesamiento de leads históricos, cargas masivas o tareas que no requieren respuesta en tiempo real.

Decisión: se recomienda solo para procesos masivos no urgentes.

Decisión final

Para el prototipo se utilizó GPT-4.1 porque permitió validar el flujo completo con una respuesta de buena calidad. Para una implementación real y sostenida, la opción recomendada es migrar el módulo de IA a GPT-4.1 mini o GPT-4o mini, ya que la tarea principal es repetitiva y de baja complejidad.

La estrategia de costos queda definida así:

- Tiempo real: GPT-4.1 mini o GPT-4o mini.
- Casos complejos o revisión puntual: GPT-4.1.
- Procesamiento masivo no urgente: Batch API.
- Control de calidad: mantener validación humana antes del envío por Gmail.